Analyse des données web de la librairie Charlemagne

2023-2024

I. Démarches et difficultés rencontrées

Ce projet de webscraping se concentre sur la collecte de pages provenant d'une librairie en ligne, avec un intérêt pour les sections dédiées aux romans pour adolescents, aux bandes dessinées (BD) et mangas, ainsi qu'aux livres pour enfants. Cette sélection restreinte vise à limiter l'ampleur de l'étude en raison du temps nécessaire à la collecte des pages. De plus, des seuils de pages à collecter ont été établis pour chaque genre afin d'obtenir des échantillons de taille similaire à des fins d'étude, bien que cet échantillonnage ne soit pas aléatoire car les pages ont été collectées dans l'ordre de publication par Charlemagne.

La première étape du processus consiste à collecter les pages, avec pour objectif la récupération des URLs de chaque livre sur chaque page. Une difficulté supplémentaire est survenue car toutes les pages ne pouvaient pas être collectées dans une seule boucle en raison de la structure d'URL différente pour la première page. Par conséquent, deux boucles *for* distinctes ont été nécessaires.

Ensuite, l'étape suivante implique l'extraction des informations à partir des pages collectées. Cette phase comprend la collecte des informations de chaque livre, tels que l'auteur, le titre, le prix, l'éditeur, etc., et leur organisation dans des bases de données spécifiques à chaque catégorie de livre. Des difficultés sont survenues lors de la collecte du titre, de l'auteur et de la disponibilité par ville.

En effet, le titre et l'auteur ont été extraits ensemble à l'aide d'une seule expression régulière, plutôt que séparément. Cela s'explique par le schéma uniforme d'apparition du titre et de l'auteur dans le code source de chaque livre. Ainsi, chaque livre suivait un format où le titre était suivi de l'auteur, séparés par un tiret, puis suivi par « Librairie Charlemagne ». Si nous avions tenté de collecter l'auteur séparément, cela aurait compliqué la tâche, car plusieurs auteurs peuvent apparaître sur une même page, notamment lorsque d'autres livres sont recommandés à la fin de la page. Tous ces auteurs sont présentés dans le code source de manière similaire au livre principal. Ainsi, nous avons choisi de partir d'une seule ligne du code source qui contient à la fois le titre et l'auteur, puis, en fonction de leur position relative par rapport aux tirets, nous avons pu extraire séparément le titre et l'auteur avec succès.

D'autres défis ont émergé concernant la localisation des données pertinentes dans le code source. Par exemple, pour obtenir la disponibilité du livre selon la ville, nous avons dû mettre en place deux expressions régulières au lieu d'une seule. Cela est dû au fait que la disponibilité « à paraître » n'était pas spécifiée de la même manière que les autres types de disponibilité.

Une autre difficulté majeure était de veiller à ce que les expressions régulières soient suffisamment précises pour ne pas extraire d'autres informations non désirées. Ainsi, la majeure partie des défis rencontrés était liée à l'étape d'extraction des données. C'est pourquoi la bibliothèque pdb a été d'une grande aide, car elle m'a permis d'extraire les bonnes parties du code source en Python et de définir toutes les conditions nécessaires pour une extraction d'information efficace.

La collecte de données des pages nous a permis de capturer plusieurs informations à propos des livres qui nous semble pertinent. Ainsi, nous avons collecté la variable ‘EAN13’ qui permet

l'identification du livre. Ensuite, nous avons collecté le titre du livre, l'éditeur, la date de publication, le nombre de pages, le poids, le prix et le statut de disponibilité du livre selon la librairie.

Enfin, la dernière étape de ce projet concerne l'analyse de données. Elle se divise en plusieurs parties. En premier lieu, nous avons effectué une analyse descriptive des bases de données créées à partir des variables récupérées sur le site. Celle-ci a permis le calcul de moyennes, variances, corrélations, etc. Etant donnée que nos bases de données sont composées de variables mixtes c'est-à-dire à la fois qualitatives et numériques. Nous avons alors également analysé les variables qualitatives à partir de la fabrication de tableau de contingence, ou encore de diagrammes en bâton. Enfin, nous avons créé une interface permettant à chaque utilisateur de pouvoir effectuer des recherches par rapport aux informations collectées sur les livres.

II. Analyse de données

Pour l'analyse de données, nous avons recueilli au total 35 144 livres dont 11 816 dans la section romans pour adolescents, 11 821 dans la section mangas et bandes dessinées et 11 504 dans la section livres pour enfants.

Nous avons effectué une analyse descriptive des données recueillies pour chaque catégorie. Tout d'abord, on constate que la variable 'prix' n'est pas disponible pour tous les livres collectés. En effet, les livres pour lesquels il n'y a pas de prix indiqué sur le site sont publiés comme 'à paraitre' c'est-à-dire qu'ils vont prochainement être ajouté à la liste des commandables ou en stock.

On retrouve dans notre échantillon, 56 romans pour adolescents dont le prix n'est pas disponible, 28 mangas et 66 livres pour enfants. Les résultats révèlent que les romans pour adolescents ont une moyenne de prix plus élevée, avec un montant moyen de 14,63 €. En comparaison, les mangas ont une moyenne de prix légèrement inférieure, s'élevant à 13,47 €, tandis que les livres pour enfants affichent la moyenne la plus basse, avec un prix moyen de 11,29 €.

En observant l'histogramme des prix des romans pour adolescents, on peut souligner que la majorité de ces livres sont vendus entre 15 et 20 euros. (Figure 1) Quant aux mangas et BD, pour la plupart sont vendus entre 5 et 10 euros. (Figure 2) La distribution est asymétrique vers la droite. Enfin, concernant les livres pour enfants, la majorité des livres vendus sont compris entre 5 et 10 euros également. (Figure 3)

Considérons maintenant la variable 'poids'. Cette fois-ci, ce sont les livres pour enfants qui répertorient le plus grand nombre de livres n'ayant pas de poids indiqué. En effet, 128 livres pour enfants sur 11 504 n'ont pas d'indication sur le poids. Cependant, très peu de livres dans la section adolescents n'ont pas d'indication sur le poids (11 livres) et 122 mangas et bandes dessinées n'ont pas de poids affichés. En moyenne, ce sont les mangas et bandes dessinées qui sont les plus lourds (441,28 g). Et pour les autres catégories, on obtient en moyenne le même poids à savoir 332 g.

Enfin, nous analysons la dernière variable continue à savoir le nombre de pages. 1 769 livres pour adolescents n'ont pas d'indication sur le nombre de pages. 666 mangas et bandes dessinées n'ont pas d'indication sur le nombre de pages. Et 333 livres pour enfants n'ont pas d'indication sur le nombre de pages. (Tableau 1)

Ensuite, nous décidons de nous intéresser à la relation entre les différentes variables continues. Est-ce que dans cet échantillon, nous pouvons observer une quelconque relation entre prix et poids ou encore prix et pages ? Nous allons principalement nous focaliser sur la visualisation de ces données à partir de graphiques.

Premièrement, nous allons voir s'il existe une relation entre prix et poids pour chaque catégorie. Nous remarquons, que la variable 'prix' possède une valeur aberrante de l'ordre de 9 000 € pour la section romans pour adolescents. Nous décidons alors de ne pas représenter cette valeur dans le graphique qui risquerait de fausser son interprétation.

En observant la figure 4, on peut voir qu'il existe une relation linéaire croissante entre prix et poids pour les romans d'adolescents dans notre échantillon. Ces deux variables sont presque parfaitement corrélées avec un coefficient de corrélation de 0,95. Pour la section mangas et BD, on observe également une relation linéaire croissante avec un coefficient de corrélation de 0,9. (figure 5) Enfin, concernant les livres pour enfants, la relation est également croissante mais semble relativement moins sensible au poids avec un coefficient de corrélation de 0,8. (Figure 6) Les livres plus lourds ont tendance à avoir un prix plus élevé, et inversement.

Maintenant, nous regardons de plus près la relation entre le prix et le nombre de pages d'un livre. Celle-ci semble moins frappante lorsque l'on regarde le graphique pour les 3 sections. (Figures 7,8 et 9). En effet, en calculant le coefficient de corrélation, on observe une relation positive pour les 3 sections mais faible (0,48 pour adolescents et 0,33 pour mangas et BD) voire très faible (0,16 pour enfants). Ainsi, la relation qui existe entre le prix et le nombre de pages est très faible comparée à celle entre le prix et le poids. Cela peut être dû au fait que le nombre de pages n'est pas un déterminant majeur du coût de production d'un livre selon les données de notre échantillon.

Maintenant, nous allons voir les évolutions des prix en fonction de la date de publication d'un livre. En d'autres termes, nous chercherons à déterminer si la date de publication a une incidence sur les fluctuations de prix. Nous avons pour cela opter pour une représentation graphique à 3 axes. Pour l'axe des abscisses, nous avons la date de publication, pour le premier axe des ordonnées nous avons la moyenne des prix pour chaque année de publication, et pour le deuxième axe nous avons le nombre de livres.

Ainsi, pour la section romans pour adolescents, il est clair que plus un livre est récent et plus son prix moyen est élevé. (Figure 10) On observe également qu'entre l'année de publication 2013 et 2023, un livre pour enfants se vend en moyenne 3,5 € plus cher. (Figure 11) On obtient un résultat intéressant pour la section BD et mangas. En effet, la courbe de la moyenne des prix est en forme de U et atteint un minimum en 2014. (Figure 12) Cette faible moyenne de prix ne semble pas provenir de la quantité de livres disponibles à cette date de publication puisqu'on observe à peu près le même nombre de livres entre 2011 et 2016 avec une variation de la moyenne des prix entre les années.

Nous allons désormais analyser la variable éditeur présente dans la base de données. Ainsi, nous allons étudier la moyenne des prix selon l'éditeur par catégorie. La question qu'on se pose ici est : est-ce qu'un éditeur pratique des prix différentiels selon le type de catégorie d'un livre ? Ainsi, nous avons comparé le prix moyen que fixe un éditeur selon la catégorie de livres qu'il propose. Pour ce faire, nous calculons la moyenne des prix pour chaque éditeur se trouvant à la fois dans deux catégories puis visualisons à travers plusieurs diagrammes en bâtons la moyenne des prix par éditeur. Les diagrammes classent les éditeurs en abscisses et la moyenne des prix en ordonnée. Les éditeurs sont classés par ordre de sorte que plus on se dirige

vers la droite et plus la moyenne de prix de la catégorie 1 est supérieure à celle de la catégorie 2 et vice-versa.

Dans le premier graphique à barres, qui compare les prix des romans pour adolescents et ceux des mangas et BD, on constate que Helvetiq affiche des prix moyens plus élevés pour les mangas (environ 30 euros) par rapport aux romans pour adolescents. De plus, des prix moyens plus élevés sont également observés pour les livres pour enfants par rapport aux romans pour adolescents. (Figure 13) Ensuite, à titre d'exemple, dans la figure 14 Caligram semble pratiquer en moyenne des prix assez proches pour les romans d'adolescents et livres pour enfants. Enfin, d'après la figure 15, lorsque l'on compare la moyenne des prix par éditeur entre la catégorie mangas et BD et livres pour enfants, on peut souligner qu'en moyenne beaucoup plus d'éditeurs pratiquent des prix pour les mangas et BD au-dessus des prix pour les livres d'enfants.

Nous allons désormais examiner le prix moyen des 3 catégories de livres en procédant à une analyse de la variance univariée (ANOVA). Mais avant cela, nous devons être certain de l'homogénéité des variances et de la normalité des 3 échantillons. Nous supposons que ces échantillons sont aléatoires pour l'étude. Tout d'abord, observons la distribution des logarithmes des prix des 3 catégories à travers le diagramme à moustache. (Figure 16) On remarque que les moyennes des prix pour les 3 catégories sont à peu près semblables. Une distinction est à noter pour les mangas et livres pour enfants pour lesquels beaucoup de valeurs aberrantes apparaissent comparé à la section romans pour adolescents.

Procédons maintenant au test de Levene qui consiste à vérifier si les variances des 3 catégories sont homogènes. Nous allons alors tester les hypothèses suivantes :

H0 : Egalité des variances des prix pour les 3 catégories

H1 : Différence de variances des prix pour les 3 catégories

Nous obtenons, une p-valeur élevée de l'ordre de 0,173. On décide alors d'accepter l'hypothèse nulle au seuil de 5%. Alors, il n'y a pas de différence significative entre les variances des prix des livres pour les 3 catégories. (Tableau 2)

Ensuite, nous effectuons le test de Shapiro-Wilk qui contribue à vérifier si les échantillons sont normalement distribués. Nous allons alors tester les hypothèses suivantes :

H0 : l'échantillon est issu d'une population normalement distribuée

H1 : l'échantillon n'est pas issu d'une population normalement distribuée

Suite à ce test, nous obtenons une p-valeur très faible pour les 3 catégories. Nous rejetons alors l'hypothèse nulle. Les données sur les prix de nos trois échantillons ne suivent donc pas une distribution normalement distribuée. Ce résultat était envisageable à la simple vue de la boite à moustache qui montrait la présence de valeurs aberrantes dans ces groupes. A noter, qu'un message d'avertissement nous mettant en garde sur le fait que ce test utilise une approximation dans le calcul de la p-valeur lorsque la taille de l'échantillon est supérieure à 5000, ce qui est notre cas ici. Ce qui a pour cause d'entrainer une moindre précision dans le calcul de la p-valeur.

Ainsi, comme l'une des conditions pour appliquer l'analyse de variance n'est pas respectée, à savoir l'hypothèse de normalité, nous allons effectuer une alternative au test d'ANOVA, le test de Kruskal-Wallis. C'est un test non paramétrique qui nécessite que les

données soient de type ordinal. Ainsi, comme nous pouvons ordonner la variable prix, ce test nous est adapté. Nous allons donc tester les hypothèses suivantes :

H0 : les échantillons indépendants proviennent de la même distribution

H1 : au moins un des échantillons indépendants ne provient pas de la même distribution

On obtient alors une p-valeur relativement faible (<0,05), donc on rejette l'hypothèse nulle. On constate alors qu'au moins un des 3 groupes a une différence de prix.

Maintenant, nous allons étudier à travers des tableaux de contingence la relation entre disponibilité d'un livre et l'emplacement géographique de celui-ci selon la catégorie du livre. Autrement, est-ce que la disponibilité d'un livre est influencé par la ville ?

Premièrement, on observe dans le tableau 3 qu'on retrouve principalement les romans pour adolescents dans le statut sur commande dans 5 librairies sur 6. Hormis pour la librairie La Soupe de l'Espace pour laquelle la totalité de ces livres ont le statut « à paraître ». Ensuite, concernant les BD et mangas, on en retrouve davantage en stock dans la librairie de Toulon qu'ailleurs. Tandis que pour toutes les autres librairies, sauf pour La Soupe de l'Espace, les BD et mangas ont pour la majorité le statut « sur commande ». (Tableau 4) On observe que la librairie La Soupe de l'Espace n'a aucun livre en stock et tous sont au statut « à paraître ». Concernant la disponibilité des livres pour enfants (tableau 5), on observe que presqu'aucun livre n'est en stock à Hyères et sont principalement disponibles sur commande dans les autres librairies. On remarque également que très peu de livres sont indisponibles dans notre échantillon.

Enfin, nous décidons de créer une interface qui peut être utilisée par les librairies et les clients pour s'informer sur les livres mis en ligne. (Tableau 6) Pour effectuer une recherche, l'utilisateur peut sélectionner le type de recherche dans une liste déroulante, saisir le mot-clé correspondant dans un champ de saisie, puis cliquer sur le bouton « Rechercher ». Les résultats de la recherche sont affichés dans une zone de texte située sous le bouton de recherche.

L'interface propose plusieurs types de recherches.

- Recherche de livres par éditeur, auteur ou titre
- Recherche du livre le moins cher pour un auteur, un éditeur donné ou titre
- Recherche du livre le plus cher pour un auteur, un éditeur donné ou titre
- Recherche de la disponibilité d'un livre selon la librairie en indiquant le titre ou le code EAN13

Ainsi, c'est un outil efficace pour rendre la recherche plus rapide. Un des éléments pris en compte lors de la création de cette interface est que l'utilisateur peut omettre d'écrire tout un titre pour trouver les informations sur le livre concerné et le programme arrive à lui trouver.

Pour finir, plusieurs limites ont été rencontrées lors de l'analyse, notamment le fait qu'il y ait seulement un nombre limité de variables qui ont été extraites des pages du site. Ce qui nous restreint en quelque sorte à l'analyse. Ensuite, il aurait été intéressant d'examiner les commentaires rapportés sur le livre, ou bien la note d'appréciation apportée, seulement aucun commentaire ni scores ne sont visibles publiquement sur le site.

Annexe

Tableau 1 : tableau des moyennes

Catégories	Prix	Poids	Pages
Romans d'adolescents	14.63	332.46	274.81
BD/Mangas	13.47	441.28	171.5
Enfants	11.29	332.74	93.27

Tableau 2 : tests statistiques

Test	Statistique test	P-valeur
Test de Levene	1.75	0.17
Test de normalité – prix adolescents	0.01	9.74e-120
Test de normalité – prix mangas/BD	0.60	2.05e-96
Test de normalité – prix enfants	0.20	4.21e-113

Tableau 3 : tableau croisé pour romans d'adolescents

Statut	Fréjus	La Valette	La Seyne	Toulon	La Soupe	Hyères
En stock	0.64	0.06	0.06	0.07	0.00	0.00
Indisponible	0.00	0.00	0.00	0.00	0.00	0.00
Sur commande	0.93	0.93	0.93	0.92	0.00	0.99
A paraître	0.01	0.01	0.01	0.01	1	0.01

Tableau 4 : tableau croisé pour les BD et mangas

Statut	Fréjus	La Valette	La Seyne	Toulon	La Soupe	Hyères
En stock	0.27	0.30	0.43	0.7	0.00	0.00
Indisponible	0.01	0.01	0.01	0.01	0.00	0.00
Sur commande	0.69	0.65	0.53	0.27	0.00	0.95
A paraître	0.03	0.83	0.03	0.02	1	0.04

Tableau 5 : tableau croisé pour les livres pour enfants

Statut	Fréjus	La Valette	La Seyne	Toulon	La Soupe	Hyères
En stock	0.33	0.44	0.31	0.37	0.00	0.00
Indisponible	0.01	0.01	0.01	0.01	0.00	0.00
Sur commande	0.61	0.50	0.63	0.57	0.00	0.91
A paraître	0.05	0.04	0.05	0.05	1	0.08

Tableau 6 : interface

Figure 1 : Histogramme des prix des romans d'adolescents

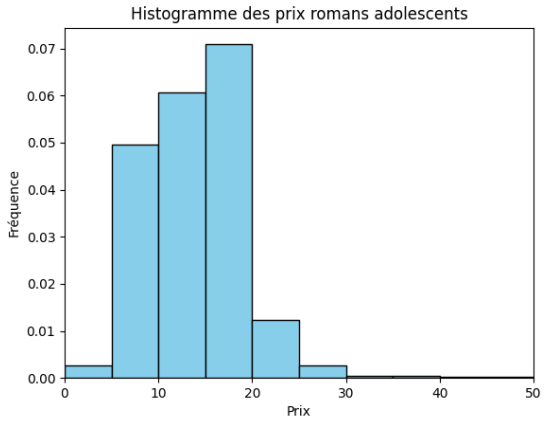

Figure 2 : Histogramme des prix des mangas

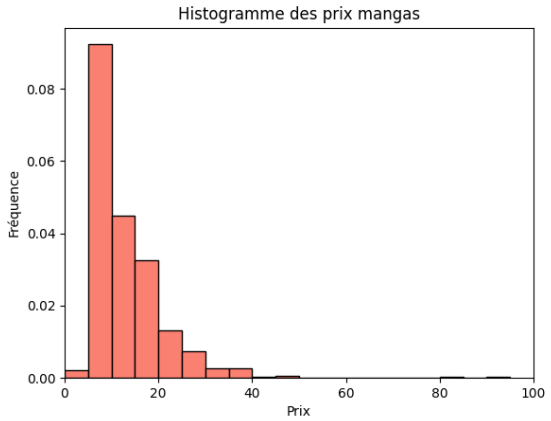

Figure 3 : Histogramme des prix des livres pour enfants

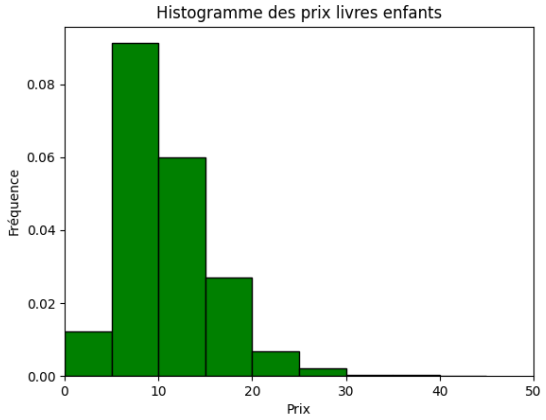

Figure 4 : Relation entre prix et poids des romans pour adolescents

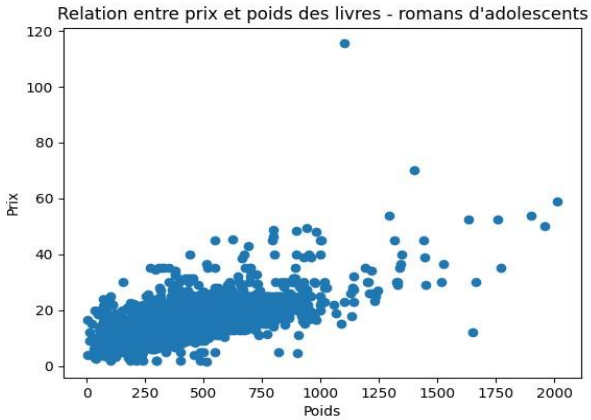

Figure 5 : Relation entre prix et poids des mangas/BD

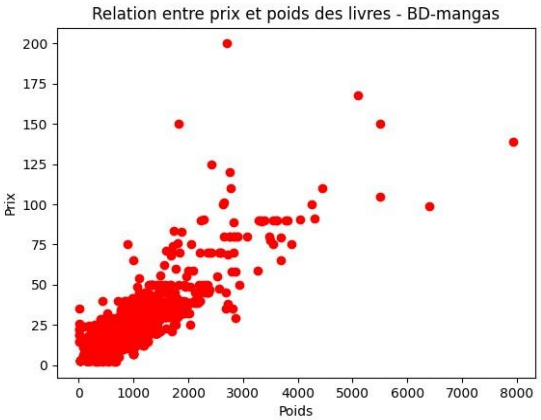

Figure 6 : Relation entre prix et poids des les livres pour enfants

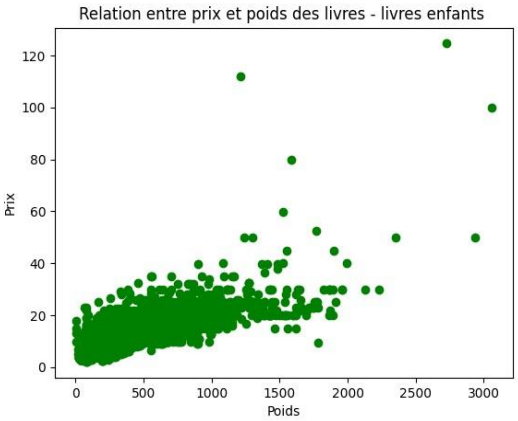

Figure 7 : Relation entre prix et pages des romans pour adolescents

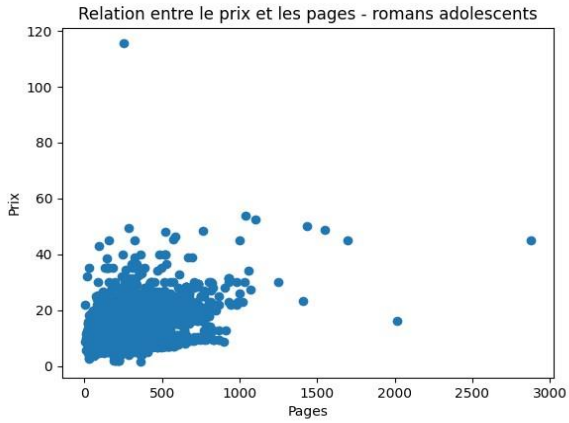

Figure 8 : Relation entre prix et pages des BD/mangas

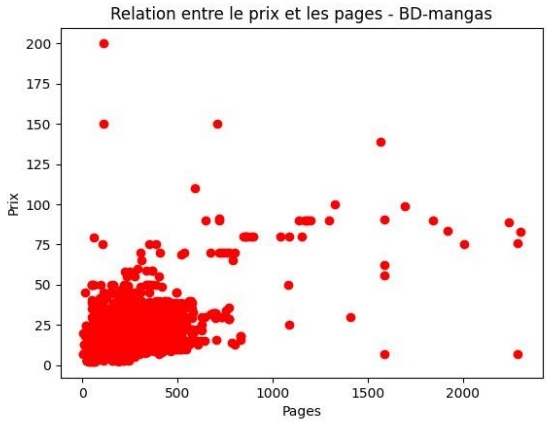

Figure 9 : Relation entre prix et pages des livres pour enfants

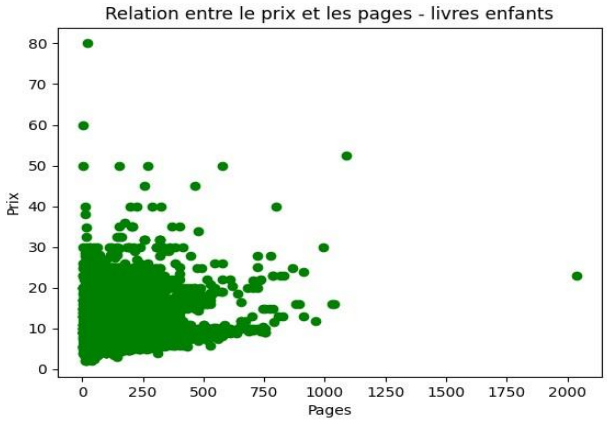

Figure 10 : évolution des prix selon l'année de publication pour les romans d'adolescents

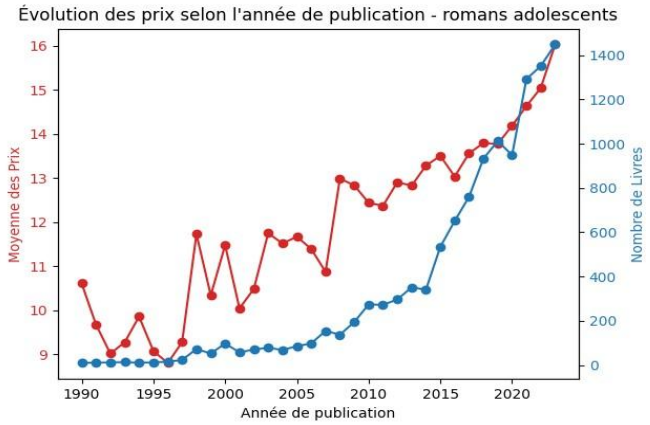

Figure 11 : évolution des prix selon l'année de publication pour les mangas/BD

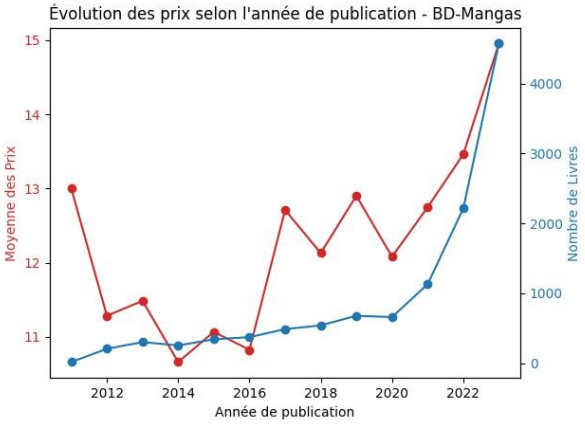

Figure 12 : évolution des prix selon l'année de publication pour les livres pour enfants

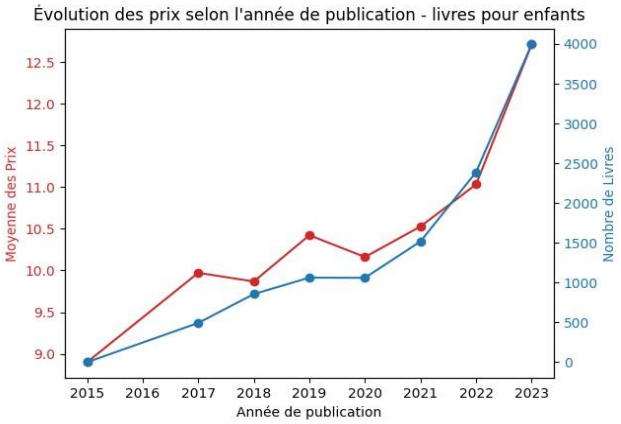

Figure 13 : diagramme en bâton de la moyenne des prix par éditeur romans d'adolescents – mangas/BD

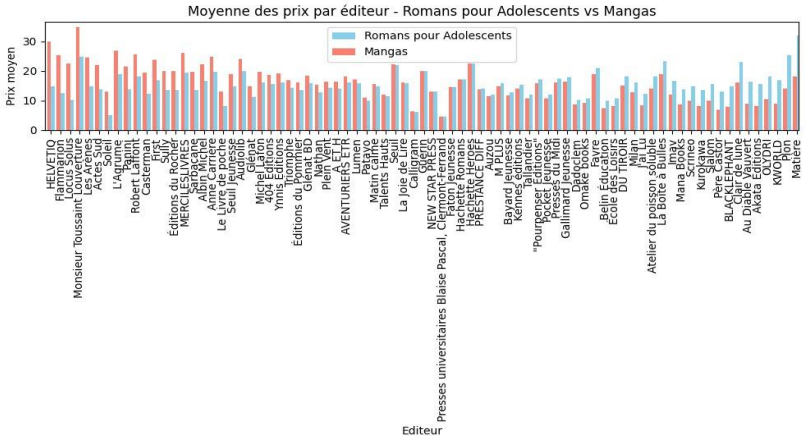

Figure 14 : diagramme en bâton de la moyenne des prix par éditeur romans d'adolescents – livres pour enfants

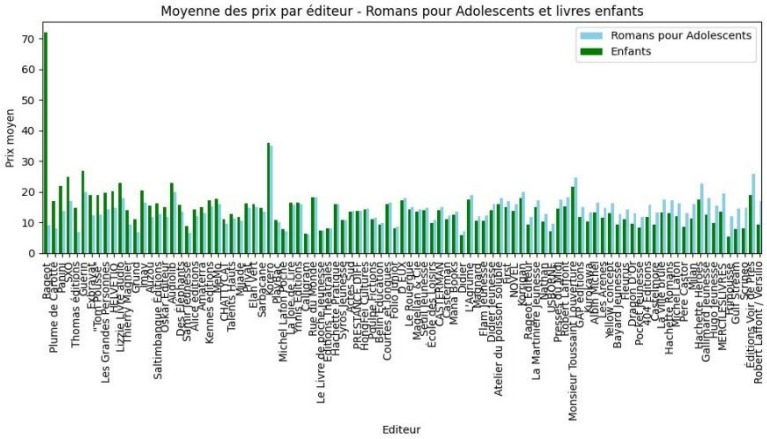

Figure 15 : diagramme en bâton de la moyenne des prix par éditeur mangas/BD – livres pour enfants

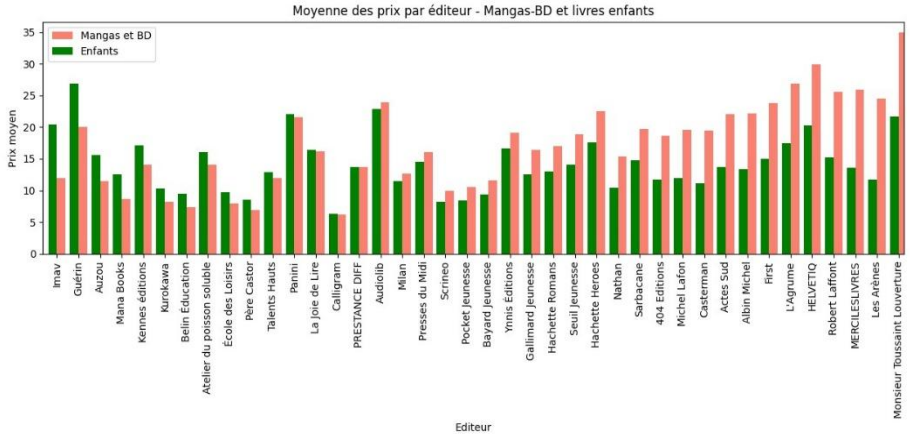
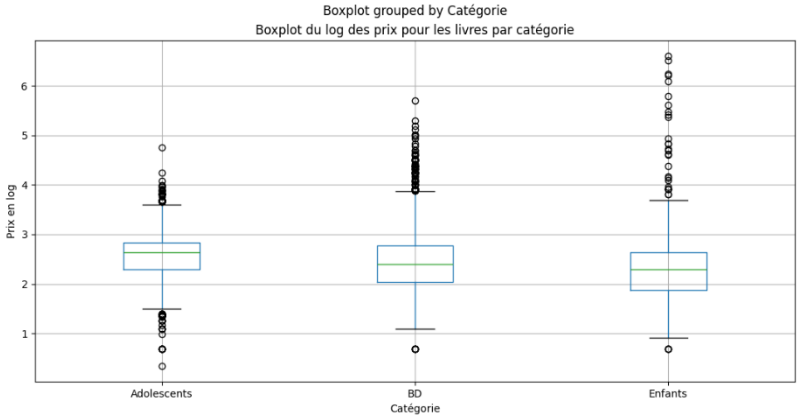
Figure 16 : Boxplot du log des prix pour les livres par catégorie